

# Reporte Gerencial: Segmentación de Clientes, Detección de Anomalías y Recomendación de Rutas

**Fecha:** septiembre 2026

**Materia:** Analítica para la Toma de Decisiones II (Segunda Entrega)

**Integrantes:** Alexandra Daniela Velez De La Hoz, Liz Dayana Rojas Cortes, Eddy Santiago Velez Monterroza

## 1. Resumen Ejecutivo

Tras optimizar los tiempos de entrega, la compañía busca comprender mejor a sus clientes, reforzar la seguridad de la operación y mejorar la satisfacción de su flota. Para ello se trabajó con los datos de 200 clientes, 85,410 cargas, 85,410 viajes, 58 rutas y 150 conductores, y se construyeron tres modelos: (1) segmentación de clientes con K-Means, (2) detección de cargas sospechosas con Mezclas Gaussianas (GMM) y (3) un sistema de recomendación basado en contenido que sugiere rutas a cada conductor.

**Hallazgos principales:** se identificaron 4 segmentos de clientes que se diferencian sobre todo por su plazo de crédito y su potencial de ingresos, y no por el volumen de carga que mueven. Destaca un segmento de 36 clientes con alto potencial (US\$3.15M) pero la facturación más baja (US\$1.19M). El modelo GMM marcó 855 cargas (1.00%) como anómalas; en promedio son 22% más livianas, recorren rutas 62% más largas y casi duplican el ingreso por libra. La revisión de una muestra enseña patrones con sentido de negocio (tarifas posiblemente sobrecobradas o subcobradas). El recomendador genera un ranking de rutas por conductor, pero tiene limitaciones que deben corregirse antes de usarlo para asignar rutas (sección 5).

## 2. Parte 1: Segmentación de Clientes (Clustering)

**2.1 Variables y justificación del modelo:** se unió el perfil contractual de cada cliente con su historial de envíos, usando seis variables: días de crédito (*credit\_terms\_days*), potencial anual de ingresos, número total de cargas, facturación total, ingreso promedio por carga y peso promedio. Las variables se estandarizaron con *StandardScaler*, porque K-Means usa distancias euclidianas y, sin escalar, las variables en millones (facturación) anularían a las pequeñas (días de crédito). Luego se aplicó PCA a 2 componentes para concentrar la información y reducir ruido antes de agrupar. Se eligió K-Means por ser un algoritmo interpretable, eficiente y adecuado para encontrar grupos compactos en variables numéricas.

### 2.2 Selección del número de clusters (Codo y Silueta)





Figura 1. Método del Codo (inercia) y Coeficiente de Silueta para  $k = 2$  a  $8$ .

El método del codo no muestra un quiebre abrupto: la inercia cae con fuerza hasta  $k=4$  (200) y después la mejora es más gradual. La silueta máxima se da en  $k=2$  (0.38), pero  $k=4$  presenta un repunte local (0.36) frente a  $k=3$  (0.35). Siguiendo la recomendación del docente, se eligió  $k=4$ : sacrifica muy poca calidad de agrupamiento a cambio de segmentos más útiles para el negocio que una simple división en dos. Una silueta cercana a 0.36 indica una separación moderada: los grupos existen, pero con fronteras que se traslapan (Figura 2).




*Figura 2. Clientes proyectados en los dos componentes principales, coloreados por cluster ( $k=4$ ).*

## 2.3 Interpretación del perfil de cada cluster

| Cluster | Clientes | Días crédito | Potencial anual (US\$) | Cargas totales | Facturación total (US\$) | Ingreso prom./carga (US\$) | Peso prom. (lbs) |
|---------|----------|--------------|------------------------|----------------|--------------------------|----------------------------|------------------|
| C0      | 36       | 36.25        | 3,153,267.69           | 398.53         | 1,189,487.05             | 2,986.27                   | 27,652.06        |
| C1      | 55       | 40.36        | 2,208,590.15           | 453.09         | 1,419,707.64             | 3,134.88                   | 27,398.82        |
| C2      | 48       | 24.06        | 1,588,794.04           | 418.92         | 1,285,158.90             | 3,068.81                   | 27,313.12        |
| C3      | 61       | 46.72        | 3,711,395.74           | 426.80         | 1,310,372.45             | 3,071.76                   | 27,585.25        |

*Tabla 1. Promedio de cada variable por cluster.* Las variables operativas (cargas, peso, ingreso por carga) son muy parecidas entre grupos; lo que realmente diferencia a los segmentos es el plazo de crédito y el potencial de ingresos.



*Figura 3. Potencial anual frente a facturación registrada y plazo de crédito promedio por cluster (valores de la Tabla 1).*

- C0 – Alto potencial subaprovechado (36 clientes): potencial alto (US\$3.15M) pero la facturación registrada más baja (US\$1.19M), el menor número de cargas (398.5) y el menor ingreso por carga (US\$2,986). Es la mayor brecha entre lo que el cliente podría comprar y lo que efectivamente compra: prioridad para el equipo comercial.
- C1 – Clientes más activos y rentables hoy (55 clientes): potencial medio (US\$2.21M) pero la mayor facturación (US\$1.42M), el mayor volumen (453 cargas) y el mayor ingreso por carga (US\$3,135). Son la base actual del negocio: retener y fidelizar.
- C2 – Cuentas pequeñas de crédito corto (48 clientes): el menor potencial (US\$1.59M) y el crédito más corto (24 días), pero una facturación comparable a la de los demás (US\$1.29M). Son clientes de bajo riesgo financiero y buena rotación de cartera: atención eficiente y de bajo costo.
- C3 – Grandes cuentas con crédito extendido (61 clientes): el mayor potencial (US\$3.71M) y el plazo de crédito más largo (46.7 días), con facturación intermedia (US\$1.31M). Representan la mayor oportunidad de crecimiento, pero también la mayor exposición de cartera: crecer la relación con seguimiento de cobro.

### 3. Parte 2: Detección de Anomalías con Mezclas Gaussianas (GMM)

#### 3.1 Ingeniería de características y justificación del modelo

Se unieron las cargas con la distancia típica de su ruta y se construyeron dos variables de negocio: ingreso por libra (*revenue / weight\_lbs*) e ingreso por milla (*revenue / typical\_distance\_miles*), que permiten detectar tarifas incongruentes frente al peso o la distancia. Junto con el peso y la distancia, se escalaron con *StandardScaler*. Se usó GMM porque es un modelo probabilístico: estima la densidad de la operación "normal" y permite calcular qué tan probable es cada carga (log-verosimilitud). Las cargas con probabilidad muy baja son las sospechosas, sin necesidad de etiquetas previas de fraude.




Figura 4. Criterios AIC y BIC según el número de componentes del GMM (muestra de 10,000 cargas).

El número de componentes se eligió con el criterio BIC, que penaliza la complejidad del modelo. Dentro del rango evaluado (1 a 9), el mínimo BIC se alcanza en 9 componentes. Como el BIC sigue bajando en el extremo del rango, es posible que más componentes ajusten mejor; esto queda como punto a revisar.

#### 3.2 Porcentaje de anomalías y comparación con cargas normales

Se marcó como anomalía toda carga cuya log-verosimilitud estuviera por debajo del percentil 1. Resultado: 855 de 85,410 cargas (1.00%). Es importante aclarar que este porcentaje lo fija el umbral elegido: el modelo no "descubre" que hay 1% de fraude, sino que prioriza el 1% de cargas más atípicas para revisión. El umbral puede ajustarse según la capacidad del equipo de auditoría.

| Grupo      | Ingreso (US\$) | Peso (lbs) | Distancia típica (mi) | Ingreso por libra | Ingreso por milla |
|------------|----------------|------------|-----------------------|-------------------|-------------------|
| Normales   | 3,064.59       | 27,538.91  | 1,380.65              | 0.13              | 2.20              |
| Anómalas   | 3,975.98       | 21,403.58  | 2,241.49              | 0.25              | 2.00              |
| Diferencia | +29.7%         | □22.3%     | +62.3%                | □ 1.9 veces       | □9.1%             |

Tabla 2. Promedios de cargas normales vs. anómalas. Las cargas anómalas son en promedio más livianas, viajan por rutas mucho más largas y cobran casi el doble por libra, aunque su ingreso por milla es algo menor.




Figura 5. Distancia típica vs. ingreso por libra (muestra de 5,000 cargas); en rojo las anomalías.

### 3.3 Validación desde la lógica de negocio (muestra de 10 cargas anómalas)

Al revisar la muestra impresa en el notebook se distinguen cuatro patrones, todos con sentido operativo:

- Cargas livianas con tarifa muy alta: LOAD00000188, 00000528 y 00000817 pesan entre 10,058 y 10,790 lbs, recorren rutas de 2,623–2,729 mi y facturan US\$6,994–7,411, con un ingreso por libra de 0.67–0.70 (más de 5 veces el promedio normal de 0.13). Posible sobrecobro, error de registro de peso o carga especial que debe verificarse.
- Ruta más larga con tarifa baja por milla: LOAD00000513, 00000521 y 00000736 van por la ruta de 3,141 mi con ingreso por milla de 1.42–1.56, por debajo del promedio normal (2.20). Posible subcobro en la ruta de mayor distancia.
- Carga pesada con ingreso muy bajo: LOAD00000874 lleva 44,882 lbs a 547 mi por solo US\$850.57 (0.019 por libra). Candidata clara a revisión de facturación.
- Rutas cortas con ingreso por milla alto: LOAD00000309, 00000536 y 00000744 tienen ingresos por milla de 2.69–2.99 en rutas de 262–720 mi. Son atípicas, pero pueden explicarse por tarifas mínimas en trayectos cortos; requieren menor prioridad.

Conclusión: las anomalías no son ruido aleatorio; señalan combinaciones de peso, distancia y tarifa que un analista de facturación consideraría sospechosas. El modelo sirve como filtro de priorización para auditoría, no como prueba de fraude.

## 4. Parte 3: Sistema de Recomendación de Rutas

### 4.1 Enfoque y justificación

Se construyó un recomendador basado en contenido. No se usó filtrado colaborativo porque no hay calificaciones de los conductores sobre las rutas. Cada ruta se representa como un vector con sus variables numéricas escaladas con *MinMaxScaler* (distancia típica, tarifa base por milla, recargo de combustible y días de tránsito) y sus variables categóricas en *one-hot* (ciudad y estado de origen y destino). El perfil de cada conductor es el promedio de las rutas que ha operado (uniendo viajes - cargas - rutas). A ambos vectores se agregó una dimensión que enfrenta la experiencia del conductor (*years\_experience*, escalada) con la distancia de la ruta como aproximación a su exigencia. Finalmente se calcula la similitud coseno entre conductor y rutas y se recomiendan las de mayor puntaje. Como hay solo 58 rutas y cada conductor acumula cientos de viajes, casi todos ya operaron el catálogo completo; por eso se rankean todas las rutas en lugar de excluir las ya operadas (la exclusión queda como opción de la función).




Figura 6. Top 5 de rutas recomendadas y su similitud coseno para los tres conductores de ejemplo.

### 4.2 Resultados e interpretación

- DRV00053 (2 años): recibe rutas hacia Portland (OR) y Los Ángeles (CA) de 1,749 a 2,627 mi y 3–4 días de tránsito, con similitudes altas (0.59–0.66). Las recomendaciones se parecen fuertemente a su historial.
- DRV00068 (14 años) y DRV00140 (25 años): reciben exactamente las mismas cinco rutas con el mismo puntaje (encabezadas por RTE00025, Miami–Seattle, 3,141 mi y 5 días), con similitudes bajas (0.30–0.38). Son rutas largas, coherentes con conductores de mayor experiencia.

El sistema cumple el requisito de combinar historial y experiencia, pero los resultados muestran dos limitaciones: (1) al conductor con solo 2 años se le recomiendan rutas largas (hasta 2,627 mi), lo que indica que la dimensión de experiencia pesa poco frente a las muchas dimensiones de ciudad y estado; y (2) dos conductores con 11 años de diferencia reciben un ranking idéntico, lo que indica que para ellos la experiencia no está diferenciando la recomendación. Antes de usarlo en producción se recomienda dar más peso a la experiencia, revisar el perfil de los conductores con poco historial y validar las recomendaciones con los despachadores.

## 5. Consideraciones Éticas y Mitigación de Sesgos

- Segmentación y trato a clientes: los clusters se basan en crédito y potencial. No deben usarse para negar servicio o endurecer condiciones de forma automática a clientes pequeños (C2); las decisiones comerciales y de crédito deben tener revisión humana.
- Anomalía no es fraude: el 1% marcado depende del umbral elegido y muchas cargas pueden tener explicaciones legítimas (carga especial, tarifa mínima). Ningún cliente o conductor debe ser sancionado solo por la alerta del modelo; cada caso requiere verificación documental y derecho a explicar.
- Experiencia como posible proxy de edad: los años de experiencia pueden correlacionar con la edad. Usarlos para repartir rutas (sobre todo las más rentables) podría generar discriminación indirecta. Se debe vigilar que la distribución de rutas e ingresos sea equitativa entre grupos de experiencia.
- Efecto de encierro (filter bubble): un recomendador basado en historial tiende a repetir lo que el conductor ya hace, limitando su desarrollo y el acceso a nuevas rutas. Conviene incluir diversidad en las sugerencias y permitir que el conductor las rechace.
- Transparencia y privacidad: los conductores deben saber qué datos se usan para sugerirles rutas; los identificadores (*driver\_id*, *customer\_id*) deben tratarse con controles de acceso y no exponerse fuera del área operativa.

## 6. Respuestas a las Preguntas de Negocio y Recomendaciones

¿Cómo es el perfil de nuestros clientes? Hay cuatro segmentos que se diferencian por crédito y potencial, no por volumen. El equipo comercial debe priorizar a C0 (mayor brecha entre potencial y facturación), fidelizar a C1 (el más rentable hoy), crecer con C3 controlando su cartera de 46.7 días y atender con eficiencia a C2.

¿Cómo mejorar la seguridad de la operación? Usar el GMM como filtro semanal que envía a auditoría el 1% de cargas más atípicas, empezando por los patrones de mayor riesgo económico: cargas livianas con ingreso por libra muy alto, cargas pesadas con ingreso muy bajo y la ruta de 3,141 mi con tarifa por milla baja. Revisar además si el número de componentes (9) debe ampliarse.

¿Cómo aumentar la satisfacción de la flota? El recomendador ya genera rankings de rutas afines a cada conductor, pero debe usarse como sugerencia para el despachador, no como asignación automática, hasta corregir el bajo peso de la experiencia y validar su efecto real en la satisfacción de los conductores